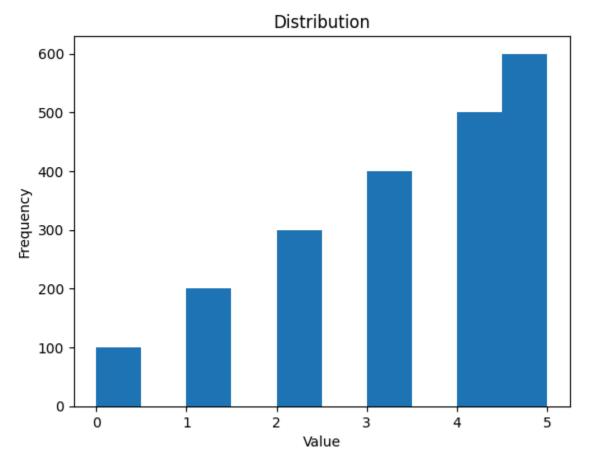
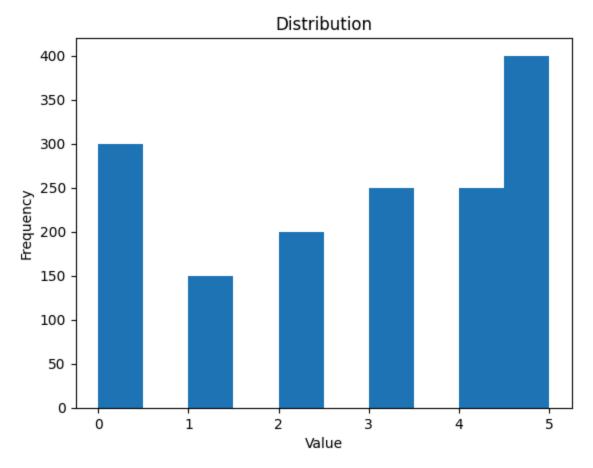
## بررسی رفتار غیرعادی کاربران در سامانه

علی گل محمدی تسک فنی بیت پین در انجام این تسک از روش های آماری استفاده شده است. با قبول این فرض که پست های ما تعداد قابل قبولی کامنت دریافت کرده اند، ما یک تخمین کلی از رفتار کاربران در کامنت گذاری بر روی مطالب داریم.

سناریو زیر را در نظر بگیرید: فرض کنیم در شرایط عادی، توزیع کامنت های دریافت شده از کاربران در یک بازه زمانی هفت روزه به شکل زیر است.



این نمودار در اصطلاح left-skewed است. یعنی کاربران در آن بیشتر مایل به امتیاز های بالاتر بوده اند. بوده اند. حال یک نمودار را در نظر بگیریم که در شرایط غیر عادی ایجاد شده است.



در این نمودار، اتفاقی که افتاده است این است که تعداد امتیاز های ۰ و ۱، به نسبت امتیاز های دیگر، افز ایش یافته است.

حال میتوان در هر زمانی که نیاز داریم میانگین امتیاز های هر مطلبی را به روز کنیم، میتوانیم با استفاده از یک تست آماری تشخیص بدهیم که آیا رفتار کاربران با شرایط عادی هفت روز گذشته مطابقت دارد یا خیر؟

یکی از این تست های آماری، آزمون کولموگروف-اسمیرنوف میباشد.

در این آزمون بررسی میشود که آیا دو نمونه داده از توزیع یکسانی پیروی میکنند یا خیر؟ با استفاده از نتیجه این تست که p\_value نام دارد، میتوان صحت سنجی کرد که رفتار کاربران عادی است.

به این صورت که اگر p\_value کمتر از 0.00 بود، یعنی حالت غیر عادی رخ داده است. در پیاده سازی این روش با کد، از کتابخانه scipy استفاده شده است.

مسیر کلی هم به این صورت است:

اول یک دیتاست کلی از رفتار کاربران در مثلا هفت روز اخیر جمع آوری میکنیم. پیش از هر آپدیتی که روی میانگین امتیاز های مطالب داشته باشیم، این تست را اجرا میکنیم. اگر شرایط عادی بود که خب امتیاز ها به روز میشوند و تمام. اما اگر شرایط غیر عادی بود، باید کلیه کامنت هایی که در این بازه ایجاد شده اند را در نظر نگیریم. این کار از طریق is\_dirty که در مدل کامنت ایجاد شده است انجام میشود.

اما چرا کلیه کامنت هایی که در این بازه ثبت شده اند را در نظر نمیگیریم و همه را dirty میکنیم؟ به این دلیل که در شرایط عادی سامانه، رفتار کلی کاربران از توزیع تاریخی آن ها پیروی میکند و انتظار تغییر به خصوصی نداریم، نکته دیگر اینکه فرض شده است هر پست به تعداد کافی کامنت دارد، در نتیجه میانگین آن ها در زمان کوتاهی تغییر بزرگی نخواهد داشت. یک نکته دیگر هم برای حفظ performance سامانه است. اگر میخواستیم پست مورد حمله را پیدا کنیم، باید یک زمان هم به آن اختصاص میدادیم که با توجه به هزینه ای که دارد و نتیجه ای که به ما

میدهد، به نظرم ارزشش را نداشت.